

AI SCIENCE HACK · TRACK 2

Научный клубок

Система извлечения знаний из научно-технических
документов горно-металлургической отрасли

— IKANAM



<http://111.88.148.105:5173/>

живое демо — попробуйте во время питча

Знания есть — получить их **НЕВОЗМОЖНО**

01 Тысячи документов без структуры

PDF, DOCX, отчёты, статьи — накоплены годами, но нет единой точки входа. Найти нужное — ручная работа на часы.

02 Факты разрознены по источникам

Процесс, материал, условие и результат описаны в разных документах — автоматически сопоставить их нельзя.

03 Нет проверяемых ответов

Обычный поиск даёт список документов. Эксперт хочет: что именно, при каких условиях, из какого источника — и с цифрами.

RAG хорошо ищет текст. Но не умеет работать с числами и связями

ОБЫЧНЫЙ RAG

-  **Нет числовой фильтрации**
«Процессы с Ni > 95% при T > 200°C» — не даст точный ответ
-  **Факты из разных документов не связаны**
Нет общей структуры между источниками
-  **Числа теряют контекст**
«220°C» — непонятно, для какого процесса и материала
-  **Ответ сложно проверить**
Нет ссылки на структурированный источник конкретного факта

НАУЧНЫЙ КЛУБОК (ГРАФ ЗНАНИЙ)

-  **Точная числовая фильтрация**
Граф хранит числа и единицы — запросы работают точно
-  **Связи между сущностями**
Процесс → Материал → Условие → Результат в одном графе
-  **Контекст сохраняется**
Каждый параметр привязан к конкретному процессу
-  **Цитируемые ответы**
Каждый факт ссылается на исходный документ

Как система превращает документы в граф знаний и отвечает на вопросы

1

Читаем документы

Система принимает научные статьи, отчёты и доклады из корпуса Норникель.

2

Находим факты

ИИ читает каждый фрагмент и выделяет: что за процесс, какие материалы, при каких условиях, какой результат.

3

Строим граф знаний

Факты связываются между собой в единую базу. Числа сохраняются точно — с единицами измерения.

4

Отвечаем на вопросы

Пользователь задаёт вопрос. Система ищет в графе и возвращает точный ответ со ссылками на источники.

ЧТО ПОПАДАЕТ В ГРАФ



Технологический процесс

Что делается с сырьём



Материал

Что используется или получается



Условия проведения

Температура, давление, время



Результат

Что получилось и насколько эффективно



Источник

Ссылка на документ — можно проверить

Онтология: 10 типов сущностей, 14 типов связей — ниже ключевые

СУЩНОСТИ

Процесс

- Технологическая операция с сырьём

Материал

- Вещество на входе или выходе процесса

Параметр

- Числовое условие или результат с единицей

Оборудование


- Агрегат, в котором идёт процесс

Объект

- Производственная площадка или предприятие

Эксперт / Орг

- Автор или организация — источник знания



СВЯЗИ

использует материал

процесс → вещество

использует оборудование

процесс → агрегат

условие проведения

процесс → число с единицей

результат процесса

процесс → число с единицей

автор документа


документ → эксперт

место проведения


эксперимент → объект

От документа до ответа

OFFLINE — ПОСТРОЕНИЕ ГРАФА



ONLINE — ОТВЕТ НА ВОПРОС

**~35**

документов
обрабатывается
параллельно

GLM-4

Flash модель
для извлечения и
ответа

Neo4j

граф + bge-m3
гибридный поиск

RRF

fusion ранжирование
вектор + граф

Вопрос эксперта — проверяемый ответ

ВОПРОС

Распределение Au, Ag и МПГ между медным, никелевым штейном и шлаком — по зарубежным источникам последних лет (вопрос №9 из списка экспертов)

Система нашла: коэффициенты распределения по 6 металлам, 20+ числовых фактов, источники: ЦМ № 01-24, СМ_09_17, СМ_12_10 («Цветные металлы», 2004–2024)

ФАКТЫ ИЗ ГРАФА

ПАРАМЕТР	ЗНАЧЕНИЕ	ИСТОЧНИК
Коэфф. распределения Pd (штейн/шлак)	128 – 264	ЦМ № 01-24
Коэфф. распределения Rh	128 – 227	ЦМ № 01-24
Извлечение Au в штейн	96,1 – 97,8 %	СМ_09_17
Извлечение Ag в штейн	65,8 – 85,8 %	СМ_09_17
Au в штейне (опыт 3)	70,41 г/т	СМ_09_17

ОТВЕТ СИСТЕМЫ

Зарубежных данных последних лет в корпусе нет — все источники российские (2004–2024): система говорит об этом честно. По лабораторным плавкам: коэффициенты распределения МПГ между штейном и шлаком — Pd **128–264**, Rh **128–227**, Ru **87–138**; извлечение Au в штейн **96,1–97,8 %**, Ag — **65,8–85,8 %**.
Источники: **ЦМ № 01-24 СМ_09_17 СМ_12_10**

✗ Противоречие: «41 150» для Pd (опыт 1) — аномалия в таблице источника, найдена системой

■ Пробел: зарубежных источников последних лет нет — все данные РФ

Реальный ответ живого стенда — воспроизводимо:
<http://111.88.148.105:5173/>

Стек: проверенные инструменты

ХРАНИЕНИЕ ДОКУМЕНТОВ

Yandex S3

1 150 файлов: PDF, DOCX, PPTX.

Структура: `parsed/` и `extracted/`

ЯЗЫКОВАЯ МОДЕЛЬ

GLM-4.7-Flash

Извлечение сущностей и связей.

Подаётся через `vLLM`, 35 параллельных вызовов

ЭМБЕДДИНГИ

bge-m3

Мультиязычные векторы 1024-dim.

Индекс хранится в Neo4j

БАЗА ЗНАНИЙ

Neo4j

Граф + векторный индекс в одной БД.

Сурpher-запросы для числовых фильтров

API-СЕРВЕР

FastAPI + asyncio

Асинхронный pipeline обработки.

Pydantic-схема для валидации

ПОИСК И СЛИЯНИЕ

RRF Fusion

Векторный + граф-поиск объединяются.

Топ-12 результатов → LLM синтез

РЕЗУЛЬТАТЫ

Что уже работает

787

документов обработано (из 1 150 корпуса)

21^{K+}

сущностей в графе знаний

15^{K+}

связей; числовые — с единицами измерения

~85[%]

точность извлечения (выборочная ручная сверка)

Зачем это нужно

1 150

Документов в корпусе

Отчёты и статьи накоплены годами. 787 обработано за сутки хакатона без ручной разметки; остальное — вопрос машинного времени, не кода.

↓ 10×

Время поиска для эксперта

Вместо часов ручного просмотра — структурированный ответ с цитатами за секунды.

Ni > 95% T > 200°C

Числовые запросы

Только граф может найти: какие процессы дают нужный результат при заданных условиях — с источниками.



Каждый факт прослеживаем

Любое число в ответе ссылается на конкретный документ. Эксперт проверяет источник в один клик.

ikanam

— AI SCIENCE HACK 2026 · TRACK 2 —

Задайте системе свой вопрос



<http://111.88.148.105:5173/>

Обзор способов удаления SO_2 из отходящих газов
Распределение Au, Ag и МПГ между штейном и шлаком
Методы очистки шахтных вод: РФ и мир